实验报告 6

AD/DA 与人工神经网络模型

范皓年 1900012739　信息科学技术学院

2020 年 11 月 21 日

目录

1 实验目的

1. 熟悉 AD/DA 原理。
2. 通过 I^2C 总线访问扩展板的 PCF8591 AD/DA 芯片。
3. 了解 keras 框架和简单的人工神经网络模型搭建。

2 实验原理

2.1 模拟和数字量的相互转换

模拟量是自然物理世界中存在的大量的连续量。而在实际的电子系统当中，模拟量的获取、保存、传输都不容易，所以我们需要把模拟量转换为离散表示的数字量，可以进行这种转换的设备称为模数（A/D）转换器。在单端输入情况下，A/D 转化启动时，对 A/D 输入的模拟信号与地之间的差值与 A/D 的最小分辨率比较，根据比较的值量化输出得到最终的 AD 值（如图 1）

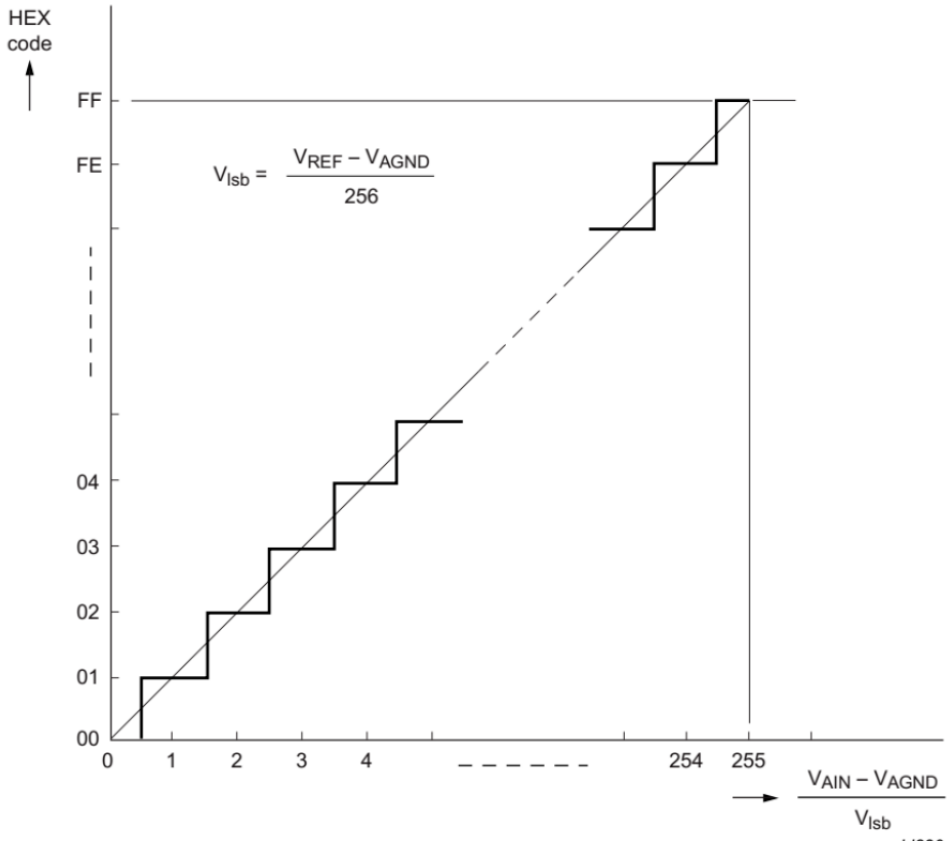

图 1: *AD* 的实现原理

计算方法为；

$$Val = \left[\frac{V_A + V_{AGND}}{V_{lsb}} + 1\right] \tag{1}$$

A/D 的最小分辨率与 A/D 的位数有关。如在 8bit 条件下，A/D 的最小分辨电压为：

$$V_{lsb} = \frac{V_{ref} - V_{gnd}}{256} \tag{2}$$

数字量经过电子系统的加工处理之后，需要重新和外界交互，要重新转换为模拟信号。把数字量转换为模拟量的设备称为数模（D/A）转换器。如图 2，数模转换根据输入（8bit 数据）进行 8bit->256 译码，将译码的输出值驱动分档开关，最后输出不同的电压值，完成 D/A 转换。

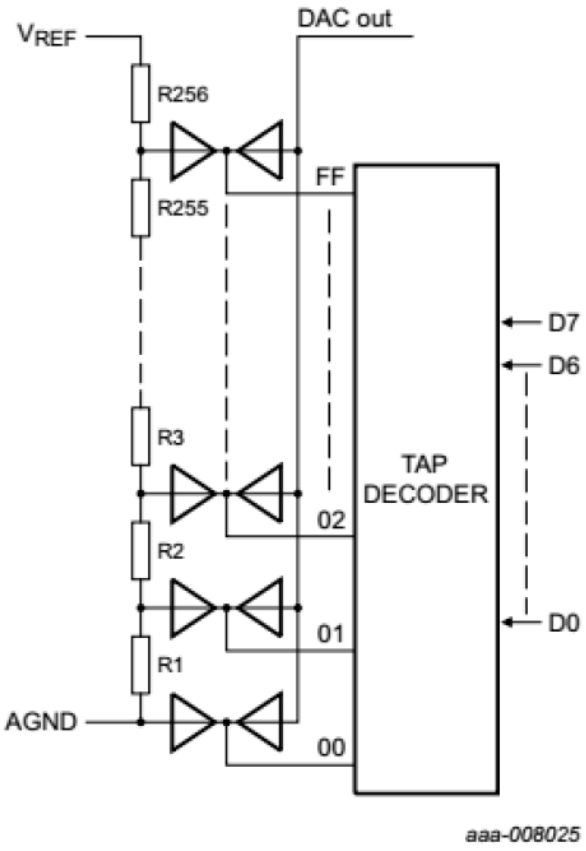

图 2: *DA* 的转换原理

对于一个 8-bit 数字信号（D0，D1，···，D7），恢复出的模拟量为：

$$V_{Ao} = \sum_{i=0}^{7} 2^i \times Di \tag{3}$$

2.2 PCF8591 芯片及其 AD/DA 操作

PCF8591 芯片也挂载在树莓派的 **I²C** 总线上，其内部框图如图3(a)所示。

扩展板上 PCF8591 的 A0/A1/A2 均接低电平，根据 PCF8591 地址配置规则（表1），PCF8591 的地址为 0x48。PCF8591 集成了多路 AD/DA 功能，在使用其功能时，需要对其控制寄存器进行控制，控制寄存器的定义如图3(b)。

控制寄存器共有 8bit，通过配置不同 bit，来实现 A/D 工作模式、通道选择及 D/A 输出功能的定义。

在树莓派端利用 Python 实现 AD/DA 的相关初始化以及 API 如下：

```
1 import smbus
2 import time # 包含相关库文件
```

位	7	6	5	4	3	2	1
地址	1	0	0	1	A2	A1	A0

表 1: *PCF8591* 地址配置

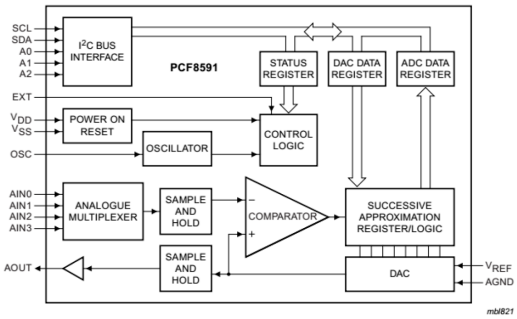

(a) PCF8591 内部框图

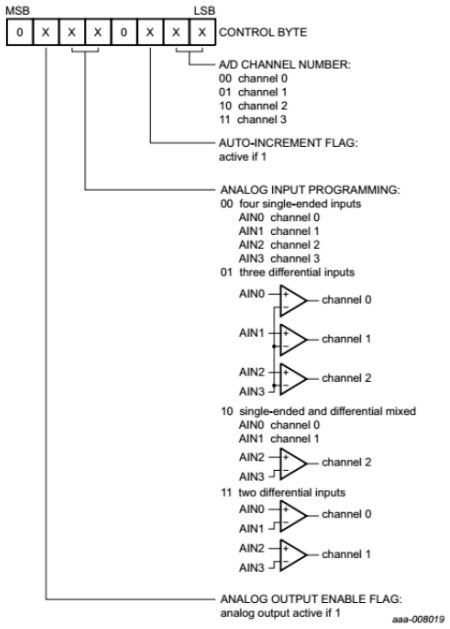

(b) PCF8591 控制寄存器定义

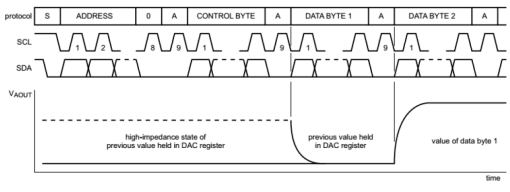

(c) PCF8591 D/A 接口时序

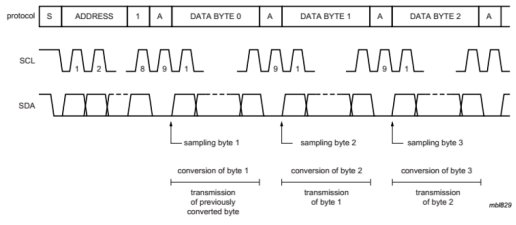

(d) PCF8591 A/D 接口时序

图 3: *PCF8591* 扩展板相关的硬件结构和性质

```
address = 0x48
A0 = 0x40
bus = smbus.SMBus(1) # 初始化 i2c Bus

# A/D: value为数字量
bus.write_byte(address,A0)
value = bus.read_byte(address)

# D/A
bus.write_byte_data(address, A0, value)
```

2.3 Python 多线程

以上的各自在一个死循环中进行 value 的读或写，显然，如果使用通常的编程方式，程序只能处在其中一个死循环中，1 从而不能有效地实现同时读写。基于这种问题，可以利用 Python 语言同时开启多个线程进行。

多线程是一种并行执行技术，在特定的应用环境下，采用并行执行的方式可以提高程序的执行效率，或者可以使程序编写简便，增加程序的可读性。实现并行执行的方法有很多种，这里介绍 threading 模块。使用 threading 模块建立线程类的简单方法是调用 Thread 构造函数：

```
from threading import Thread
mythread = Thread(target=callable, args=())
```

其中 callable 是新建线程所运行的函数名，在主程序中可以通过 mythread.start() 启动线程，调用 mythread.join() 等待线程结束。如果希望主程序退出时，线程可以自动退出，可以通过 mythread.setDaemon(True) 来设置。

需要注意的是这里的并行并没有利用多核处理器同时执行，而是采用分时的方式使得两部分的程序看起来都在运行。而在所有的并行运行技术中，都要注意共享资源的使用，避免竞争和死锁。

2.4 Pytorch 的神经网络相关组件

PyTorch 是由 Facebook 的人工智能研究小组在 2016 年开发的基于 Torch 的 Python 机器学习库。Pytorch 是 torch 的 python 版本，是由 Facebook 开源的神经网络框架。PyTorch 的程序可以立即执行计算，这正好符合 Python 的编程方法，不需要完成全部代码才能运行，可以轻松的运行部分代码并实时检查。PyTorch 支持互动式的调试，使得调试和可视化变得非常容易。与 Tensorflow 的静态计算图不同，PyTorch 的计算图是动态的，以便可以在运行时构建计算图，甚至在运行时更改它们，在不知道创建神经网络需要多少内存的情况下这非常有价值。PyTorch 可以顺利地与 Python 数据科学栈集成。它非常类似于 numpy，甚至注意不到它们的差别。

对 PyTorch 的最基本理解包括如下三方面：

1. Numpy 风格的 Tensor（张量）操作
2. 变量自动求导

3. 神经网络层与损失函数优化等高层封装

Numpy 风格的 Tensor（张量）操作。Tensor 是神经网络框架中重要的基础数据类型，可以简单理解为 N 维数组的容器对象。tensor 之间的通过运算进行连接，从而形成计算图。PyTorch 中 tensor 提供的 API 参考了 Numpy 的设计，因此熟悉 Numpy 的用户基本上可以无缝理解并创建和操作 tensor，同时 torch 中的数组和 Numpy 数组对象可以无缝的对接。Torch 定义了七种 CPU tensor 类型和八种 GPU tensor 类型，torch 模块内提供了操作 tensor 的接口，而 Tensor 类型的对象上也设计了对应了接口，例如 torch.add() 与 tensor.add() 等价。

变量自动求导。tensor 对象通过一系列的运算可以组成动态图，每个 tensor 对象可以方便的计算自己对目标函数的梯度。这样就可以方便的实现神经网络的后向传播过程。

神经网络层与损失函数优化等高层封装。网络层的封装存在于 torch.nn 模块，损失函数由.functional 模块提供，优化函数由 torch.optim 模块提供。

本实验中需要使用到网络层 torch.nn 模块，它提供了创建神经网络的基础构件，这些层都继承自 Module 类。在 nn.functional 模块中，提供多种激活函数的实现。通常对于可训练参数的层使用 module，而对于不需要训练参数的层如 softmax 这些，可以使用 functional 中的函数。

在实验二中我们使用了简单的线性模型人工神经网络，实际上更常见的人工神经网络会有更多的层，中间的层称为隐藏层。

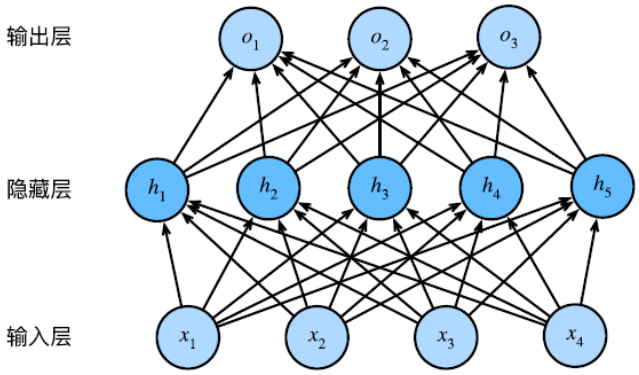

图 4

如图4是含一个隐藏层的网络。由于线性变换的组合仍然是线性变换，为了体现多层模型的价值，在每个感知器模型中都引入了非线性的激活函数如图7。

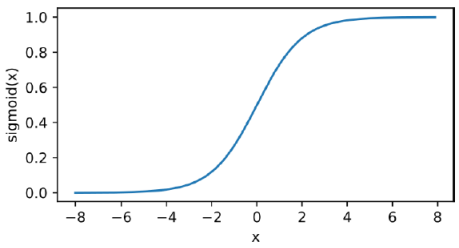

图 5: *Sigmoid*

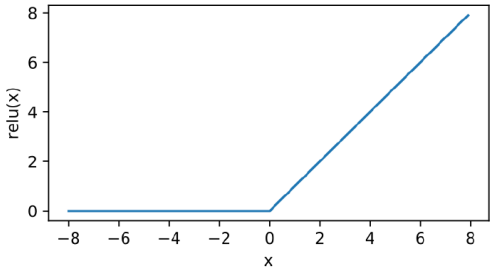

图 6: *ReLU*

图 7: 常见的非线性激活函数

用 PyTorch 定义如图7所示 MLP 神经网络的代码如下：

```
import torch.nn as nn
import torch.nn.functional as F
class Net(nn.Module):
    def __init__(self):
        super(Net, self).__init__()
        self.hidden = nn.Linear(3, 5)
        self.out = nn.Linear(5, 4)
    def forward(self, x):
        x = F.relu(self.hidden(x))
        x = self.out(x)
        return x
net=Net()
print(net)
```

2.5 人工神经网络解析

如图4给出了一个含隐藏层、非线性激活函数的人工神经网络，我们接下来给出一个多层感知机的实例，来具体说明人工神经网络的实现。

神经网络通常可以由如下步骤架构：

1. 准备数据
2. 定义网络结构 model
3. 定义损失函数
4. 定义优化算法 optimizer
5. 训练
6. 准备好 tensor 形式的输入数据和标签（可选）
7. 前向传播计算网络输出 output 和计算损失函数 loss
8. 反向传播更新参数：
9. 将上次迭代计算的梯度值清 0：optimizer.zero_grad()
10. 反向传播，计算梯度值：loss.backward()
11. 更新权值参数：optimizer.step()
12. 保存训练集上的 loss 和验证集上的 loss 以及准确率以及打印训练信息。（可选）
13. 图示训练过程中 loss 和 accuracy 的变化情况（可选）
14. 在测试集上测试

接下来的实例也将根据这个过程进行架构：

```
import torch
import torch.nn as nn
import torchvision
import torchvision.transforms as transforms
# 设备配置，部署GPU加速
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
# Hyper-parameters，定义各层规模及其他超参数
input_size = 784
hidden_size = 500
num_classes = 10
num_epochs = 5
batch_size = 100
learning_rate = 0.001
# MNIST dataset，准备数据集，转换为Tensor数据格式
train_dataset = torchvision.datasets.MNIST(root='data',
                                           train=True,
                                           transform=transforms.ToTensor(),
                                           download=True)
test_dataset = torchvision.datasets.MNIST(root='data',
                                          train=False,
                                          transform=transforms.ToTensor())
# DataLoader类，进行batch_size(每个batch的大小),
# shuffle(是否进行shuffle操作),
# num_workers(加载数据的时候使用几个子进程)等操作
train_loader = torch.utils.data.DataLoader(dataset=train_dataset,
                                           batch_size=batch_size,
                                           shuffle=True)
test_loader = torch.utils.data.DataLoader(dataset=test_dataset,
                                          batch_size=batch_size,
                                          shuffle=False)
# 定义网络结构，Fully connected neural network with one hidden layer

class NeuralNet(nn.Module):
    def __init__(self, input_size, hidden_size, num_classes):
        super(NeuralNet, self).__init__()
        self.fc1 = nn.Linear(input_size, hidden_size)
        self.relu = nn.ReLU()
        self.fc2 = nn.Linear(hidden_size, num_classes)

def forward(self, x):
```

```
    # 向前传播，模型的计算流程
    out = self.fc1(x)
    out = self.relu(out)
    out = self.fc2(out)
    return out

model = NeuralNet(input_size, hidden_size, num_classes)
# Loss and optimizer
# 定义损失函数，使用的是交叉熵函数
criterion = nn.CrossEntropyLoss()
# 定义迭代优化算法，使用的是Adam (Adaptive Moment Estimation)
optimizer = torch.optim.Adam(model.parameters(), lr=learning_rate)
# Train the model 迭代训练

def train_model(model, train_loader):
    total_step = len(train_loader)
    for epoch in range(num_epochs):
        for i, (images, labels) in enumerate(train_loader):
            # Move tensors to the configured device
            images = images.reshape(-1, 28 * 28).to(device)
            labels = labels.to(device)
            # Forward pass, 前向传播计算网络结构的输出结果
            outputs = model(images)
            # 计算损失函数
            loss = criterion(outputs, labels)
            # Backward and optimize 反向传播更新参数
            # 将上次迭代计算的梯度值清0
            optimizer.zero_grad()
            # 反向传播，计算梯度值
            loss.backward()
            # 更新权值参数
            optimizer.step()
            # 打印训练信息
            if (i + 1) % 100 == 0:
                print('Epoch [{}/{}], Step [{}/{}], loss: {:.4f}'
                .format(epoch + 1, num_epochs, i + 1, total_step, loss.item()))

    # 保存训练好的模型
    torch.save(model.state_dict(), 'model.ckpt')
def test_model(model, test_loader, device):
    model.load_state_dict(torch.load('model.ckpt', map_location=device))
```

```
    with torch.no_grad():
        correct = 0
        total = 0
        for images, labels in test_loader:
            images = images.reshape(-1, 28 * 28).to(device)
            labels = labels.to(device)
            outputs = model(images)
            _, predicted = torch.max(outputs.data, 1)
            total += labels.size(0)
            correct += (predicted == labels).sum().item()
        print('Accuracy is: {}%'.format(100 * correct / total))
train_model(model, train_loader)
test_model(model, test_loader, device)
```

深度学习框架中涉及很多参数，下面介绍一下 batch、iterations 和 epochs 的概念：深度学习的优化算法，即梯度下降，每次的参数更新有两种方式：

1. 遍历全部数据集算一次损失函数，然后算函数对各个参数的梯度，更新梯度。这种方法每更新一次参数都要把数据集里的所有样本都看一遍，计算量开销大，计算速度慢，不支持在线学习，这称为 Batch gradient descent，批梯度下降。

2. 每看一个数据就算一下损失函数，然后求梯度更新参数，这个称为随机梯度下降，stochastic gradient descent。这个方法速度比较快，但是收敛性能不太好，可能在最优点附近晃来晃去，得不到最优点。两次参数的更新也有可能互相抵消掉，造成目标函数震荡的比较剧烈。

为了克服两种方法的缺点，现在一般采用的是一种折中手段，mini-batch gradient decent，小批的梯度下降，这种方法把数据分为若干个批，按批来更新参数，这样，一个批中的一组数据共同决定了本次梯度的方向，下降起来就不容易跑偏，减少了随机性。另一方面因为批的样本数与整个数据集相比小了很多，计算量也不是很大。基本上现在的梯度下降都是基于 mini-batch 的，所以深度学习框架的函数中经常会出现 batch_size，就是指这个。

每一次迭代都是一次权重更新，每一次权重更新需要 batch_size 个数据进行 Forward 运算得到损失函数，再 BP 算法更新参数。1 个 iteration 等于使用 batch_size 个样本训练一次。

epochs 被定义为向前和向后传播中所有批次的单次训练迭代。这意味着 1 个周期是整个输入数据的单次向前和向后传递。简单说，epochs 指的就是训练过程中数据将被“轮”多少次。

例如，训练集有 1000 个样本，batchsize=10，那么训练完整个样本集需要：100 次 iteration，1 次 epoch。

3 实验内容

3.1 AD/DA 相关模块的使用

实验电路图如下：

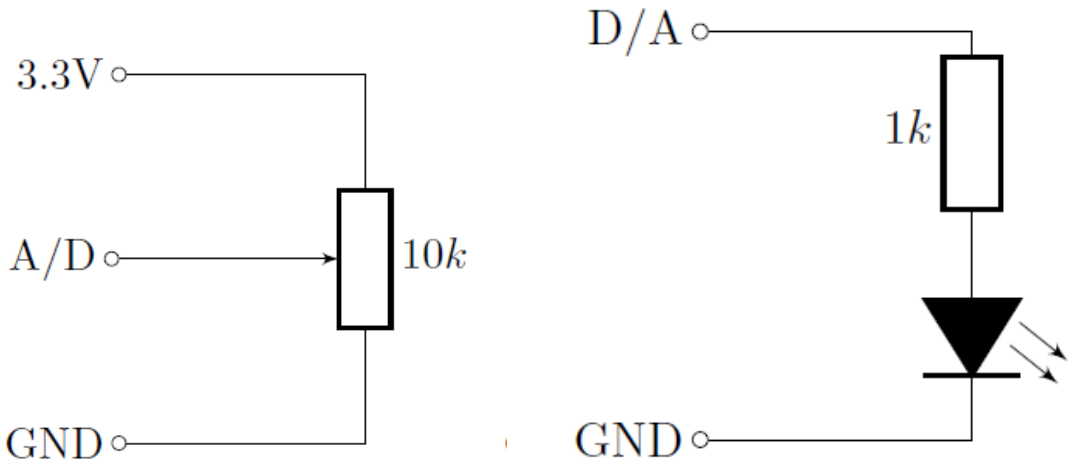

(a) 滑动变阻器电路 (b) 发光二极管电路

图 8: *AD/DA* 实验电路图

3.1.1 AD 实验

使用面包板，对电位器的电压信号进行采样并存储，在 OLED 屏幕上展示信号的电压信息。参考电路如图8(a)。

利用 AD 原理以及 Python 相关模块进行读出对应分压。通过先前 OLED 实验中的代码将电压值进行转换后显示在 OLED 屏幕上，利用代码将思路表示如下：

```
# AD相关模块导入
import smbus
import time

# SPI相关模块导入
import spidev as SPI
import SSD1306
from PIL import Image # 调用相关库文件
from PIL import ImageDraw
from PIL import ImageFont
RST = 19
DC = 16
bus = 0
device = 0 # 树莓派管脚配置

# 初始化屏幕相关参数及清屏
disp = SSD1306.SSD1306(rst=RST,dc=DC,spi=SPI.SpiDev(bus,device))
disp.begin()
disp.clear()
```

```
disp.display()
font = ImageFont.load_default()
# 显示欢迎界面
image = Image.new('RGB',(disp.width,disp.height),'black').convert('1')
draw = ImageDraw.Draw(image)
x = 30; y = 30;
draw.text((x,y), 'Hello , Pi!!', font=font, fill=255)
disp.image(image)
disp.display()
time.sleep(1)
disp.clear()
disp.display() # 初始化屏幕相关参数及清屏

# 进行OLED显示
address = 0x48
A0 = 0x40
bus = smbus.SMBus(1)
while True:
    bus.write_byte(address, A0)
    value = bus.read_byte(address) # 读出A/D端口中的电压值
    voltage = value / 256 * 3.3 # 进行转换
    # 显示
    font = ImageFont.load_default()
    image = Image.new('RGB',(disp.width,disp.height),'black').convert('1')
    draw = ImageDraw.Draw(image)
    x = 30; y = 30;
    draw.text((x,y), 'Voltage: %.4f'%voltage, font=font, fill=255)
    disp.image(image)
    disp.display()
    print(voltage)
```

3.1.2 DA 操作

调整 DA 输出，点亮发光二极管，设计二极管的发光模式（如呼吸灯）。参考电路如图8(b)。将亮度作为数字值一次轮番遍历，并将此值转化为模拟值输出到电路中完成周期性上拉实现呼吸灯。代码如下：

```
import smbus
import time

address = 0x48
A0 = 0x40
bus = smbus.SMBus(1)
```

```
7
8  while True:
9      for value in range(256):
10         bus.write_byte_data(address, A0, value)
11         print(value)
12     for value in range(255, -1, -1):
13         bus.write_byte_data(address, A0, value)
14         print(value)
```

3.1.3 AD/DA 联动：利用电位控制呼吸灯频率

在3.1.1中我们容易将电位读出，呼吸灯的频率控制，利用 time.sleep() 实现。在每个循环中，停息时间较长，则频率较低，反之频率较长。

注意其中的 AD/DA 分成两个线程实现。用于 AD 读取控制电压的程序利用函数封装进入子线程进行循环。DA 输出电压控制频率的程序直接在主函数中实现。这样能保证两个死循环互不干扰，且读取没有时间延迟：

```
1  import smbus
2  import time
3  from threading import Thread
4
5  import spidev as SPI
6  import SSD1306
7  from PIL import Image # 调用相关库文件
8  from PIL import ImageDraw
9  from PIL import ImageFont
10 RST = 19
11 DC = 16
12 bus = 0
13 device = 0 # 树莓派管脚配置
14
15 disp = SSD1306.SSD1306(rst=RST,dc=DC,spi=SPI.SpiDev(bus,device))
16 disp.begin()
17 disp.clear()
18 disp.display() # 初始化屏幕相关参数及清屏
19 font = ImageFont.load_default()
20 image = Image.new('RGB',(disp.width,disp.height),'black').convert('1')
21 draw = ImageDraw.Draw(image)
22 x = 30; y = 30;
23 draw.text((x,y), 'Hello , Pi!!', font=font, fill=255)
24 disp.image(image)
25 disp.display()
```

```
time.sleep(1)
disp.clear()
disp.display() # 初始化屏幕相关参数及清屏

address = 0x48
A0 = 0x40
bus = smbus.SMBus(1)
value = 0

def ad_read():
    global value
    while True:
        bus.write_byte(address, A0)
        value = bus.read_byte(address)
        voltage = value / 256 * 3.3
        font = ImageFont.load_default()
        image = Image.new('RGB',(disp.width,disp.height),'black').convert('1')
        draw = ImageDraw.Draw(image)
        x = 30; y = 30;
        draw.text((x,y), 'Voltage: %.4f'%voltage, font=font, fill=255)
        disp.image(image)
        disp.display()

mythread = Thread(target = ad_read)
mythread.setDaemon(True)

try:
    mythread.start()
    while True:
        for i in range(256):
            bus.write_byte_data(address, A0, i)
            if value == 0:
                value = 0.1
            time.sleep(1/value)
        for i in range(255, -1, -1):
            bus.write_byte_data(address, A0, i)
            if value == 0:
                value = 0.1
            time.sleep(1/value)
except KeyboardInterrupt:
    pass
```

3.2 利用 PyTorch 模型建立简单的多层感知机

将2.5中的的代码进行重构，将其中 MNIST 的图片数据集换成 scikit-learn 的 datasets 中的 8*8 数据。有如下几个要点；

- 将输入数据规模换成 64
- 导入数据之后将前半和后半分开成为训练数据和检验数据
- 导入图片要将 16 级归一化成为 torch 的图片数据格式
- 图片 reshape 参数时要将 28*28 换成 8*8
- 将标签 labels reshape

```
import torch
import torch.nn as nn
import torchvision
import torchvision.transforms as transforms
from sklearn import datasets
# 设备配置，部署GPU加速
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
# Hyper-parameters，定义各层规模及其他超参数
input_size = 64 # 将输入数据规模换成64
hidden_size = 500
num_classes = 10
num_epochs = 5
batch_size = 100
learning_rate = 0.001

# sklearn dataset，准备数据集，转换为Tensor数据格式
digits = datasets.load_digits()
# 导入图片要将16级归一化成为torch的图片数据格式
images_and_labels = list(zip(torch.from_numpy(digits.images/16).float(),
        torch.from_numpy(digits.target).long()))
n_samples = len(digits.images)

# 导入数据之后将前半和后半分开成为训练数据和检验数据
train_loader = images_and_labels[:n_samples//2]
test_loader = images_and_labels[n_samples//2:]
# 定义网络结构，Fully connected neural network with one hidden layer
class NeuralNet(nn.Module):
    def __init__(self, input_size, hidden_size, num_classes):
        super(NeuralNet, self).__init__()
        self.fc1 = nn.Linear(input_size, hidden_size)
```

```
        self.relu = nn.ReLU()
        self.fc2 = nn.Linear(hidden_size, num_classes)
    def forward(self, x):
        # 向前传播，模型的计算流程
        out = self.fc1(x)
        out = self.relu(out)
        out = self.fc2(out)
        return out

model = NeuralNet(input_size, hidden_size, num_classes)
# Loss and optimizer
# 定义损失函数，使用的是交叉熵函数
criterion = nn.CrossEntropyLoss()
# 定义迭代优化算法，使用的是Adam（Adaptive Moment Estimation）
optimizer = torch.optim.Adam(model.parameters(), lr=learning_rate)
# Train the model 迭代训练
def train_model(model, train_loader):
    total_step = len(train_loader)
    for epoch in range(num_epochs):
        for i, (images, labels) in enumerate(train_loader):
            # Move tensors to the configured device
            # 图片reshape参数时要将28*28换成8*8,
            images = images.reshape(-1, 8 * 8).to(device)
            labels = labels.reshape(1).to(device)

            # Forward pass, 前向传播计算网络结构的输出结果
            outputs = model(images)
            # 计算损失函数
            loss = criterion(outputs, labels)
            # Backward and optimize 反向传播更新参数
            # 将上次迭代计算的梯度值清0
            optimizer.zero_grad()
            # 反向传播，计算梯度值
            loss.backward()
            # 更新权值参数
            optimizer.step()
            # 打印训练信息
            if (i + 1) % 100 == 0:
                print('Epoch [{}/{}], Step [{}/{}], loss: {:.4f}'
                .format(epoch + 1, num_epochs, i + 1, total_step, loss.item()))
    # 保存训练好的模型
```

```
    torch.save(model.state_dict(), 'model_skl.ckpt')

# Test the model 测试模型
def test_model(model, test_loader, device):
    model.load_state_dict(torch.load('model_skl.ckpt', map_location=device))
    with torch.no_grad():
        correct = 0
        total = 0
        for images, labels in test_loader:
            images = images.reshape(-1, 8 * 8).to(device)
            labels = labels.reshape(1).to(device)
            outputs = model(images)
            _, predicted = torch.max(outputs.data, 1)
            total += labels.size(0)
            correct += (predicted == labels).sum().item()
        print('Accuracy is: {}%'.format(100 * correct / total))

train_model(model, train_loader)
test_model(model, test_loader, device)
```

A 附录代码

A.1 ad.py

```
import smbus
import time

import spidev as SPI
import SSD1306
from PIL import Image # 调用相关库文件
from PIL import ImageDraw
from PIL import ImageFont
RST = 19
DC = 16
bus = 0
device = 0 # 树莓派管脚配置

disp = SSD1306.SSD1306(rst=RST,dc=DC,spi=SPI.SpiDev(bus,device))
disp.begin()
disp.clear()
disp.display() # 初始化屏幕相关参数及清屏
```

```
font = ImageFont.load_default()
image = Image.new('RGB',(disp.width,disp.height),'black').convert('1')
draw = ImageDraw.Draw(image)
x = 30; y = 30;
draw.text((x,y), 'Hello , Pi!!', font=font, fill=255)
disp.image(image)
disp.display()
time.sleep(1)
disp.clear()
disp.display() # 初始化屏幕相关参数及清屏

address = 0x48
A0 = 0x40
bus = smbus.SMBus(1)
while True:
    bus.write_byte(address, A0)
    value = bus.read_byte(address)
    voltage = value / 256 * 3.3
    font = ImageFont.load_default()
    image = Image.new('RGB',(disp.width,disp.height),'black').convert('1')
    draw = ImageDraw.Draw(image)
    x = 30; y = 30;
    draw.text((x,y), 'Voltage: %.4f'%voltage, font=font, fill=255)
    disp.image(image)
    disp.display()
    print(voltage)
```

A.2 da.py

```
import smbus
import time

address = 0x48
A0 = 0x40
bus = smbus.SMBus(1)

while True:
    for value in range(256):
        bus.write_byte_data(address, A0, value)
        print(value)
    for value in range(255, -1, -1):
```

```
        bus.write_byte_data(address, A0, value)
        print(value)
```

A.3 adda.py

```
import smbus
import time
from threading import Thread

import spidev as SPI
import SSD1306
from PIL import Image # 调用相关库文件
from PIL import ImageDraw
from PIL import ImageFont
RST = 19
DC = 16
bus = 0
device = 0 # 树莓派管脚配置

disp = SSD1306.SSD1306(rst=RST,dc=DC,spi=SPI.SpiDev(bus,device))
disp.begin()
disp.clear()
disp.display() # 初始化屏幕相关参数及清屏
font = ImageFont.load_default()
image = Image.new('RGB',(disp.width,disp.height),'black').convert('1')
draw = ImageDraw.Draw(image)
x = 30; y = 30;
draw.text((x,y), 'Hello , Pi!!', font=font, fill=255)
disp.image(image)
disp.display()
time.sleep(1)
disp.clear()
disp.display() # 初始化屏幕相关参数及清屏

address = 0x48
A0 = 0x40
bus = smbus.SMBus(1)
value = 0

def ad_read():
    global value
```

```
    while True:
        bus.write_byte(address, A0)
        value = bus.read_byte(address)
        voltage = value / 256 * 3.3
        font = ImageFont.load_default()
        image = Image.new('RGB',(disp.width,disp.height),'black').convert('1')
        draw = ImageDraw.Draw(image)
        x = 30; y = 30;
        draw.text((x,y), 'Voltage: %.4f'%voltage, font=font, fill=255)
        disp.image(image)
        disp.display()

mythread = Thread(target = ad_read)
mythread.setDaemon(True)

try:
    mythread.start()
    while True:
        for i in range(256):
            bus.write_byte_data(address, A0, i)
            if value == 0:
                value = 0.1
            time.sleep(1/value)
        for i in range(255, -1, -1):
            bus.write_byte_data(address, A0, i)
            if value == 0:
                value = 0.1
            time.sleep(1/value)
except KeyboardInterrupt:
    pass
```

A.4 nnsklearn.py

```
import torch
import torch.nn as nn
import torchvision
import torchvision.transforms as transforms
from sklearn import datasets
# 设备配置，部署GPU加速
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
# Hyper-parameters, 定义各层规模及其他超参数
```

```
input_size = 64
hidden_size = 500
num_classes = 10
num_epochs = 5
batch_size = 100
learning_rate = 0.001
# sklearn dataset, 准备数据集, 转换为Tensor数据格式
digits = datasets.load_digits()
images_and_labels = list(zip(torch.from_numpy(digits.images/16).float(), torch.from_n
n_samples = len(digits.images)

train_loader = images_and_labels[:n_samples//2]
test_loader = images_and_labels[n_samples//2:]
# 定义网络结构, Fully connected neural network with one hidden layer
class NeuralNet(nn.Module):
    def __init__(self, input_size, hidden_size, num_classes):
        super(NeuralNet, self).__init__()
        self.fc1 = nn.Linear(input_size, hidden_size)
        self.relu = nn.ReLU()
        self.fc2 = nn.Linear(hidden_size, num_classes)
    def forward(self, x):
        # 向前传播, 模型的计算流程
        out = self.fc1(x)
        out = self.relu(out)
        out = self.fc2(out)
        return out

model = NeuralNet(input_size, hidden_size, num_classes)
# Loss and optimizer
# 定义损失函数, 使用的是交叉熵函数
criterion = nn.CrossEntropyLoss()
# 定义迭代优化算法, 使用的是Adam (Adaptive Moment Estimation)
optimizer = torch.optim.Adam(model.parameters(), lr=learning_rate)
# Train the model 迭代训练
def train_model(model, train_loader):
    total_step = len(train_loader)
    for epoch in range(num_epochs):
        for i, (images, labels) in enumerate(train_loader):
            # Move tensors to the configured device
            images = images.reshape(-1, 8 * 8).to(device)
            labels = labels.reshape(1).to(device)
```

```
50
51              # Forward pass, 前向传播计算网络结构的输出结果
52              outputs = model(images)
53              # 计算损失函数
54              loss = criterion(outputs, labels)
55              # Backward and optimize 反向传播更新参数
56              # 将上次迭代计算的梯度值清0
57              optimizer.zero_grad()
58              # 反向传播, 计算梯度值
59              loss.backward()
60              # 更新权值参数
61              optimizer.step()
62              # 打印训练信息
63              if (i + 1) % 100 == 0:
64                  print('Epoch [{}/{}], Step [{}/{}], loss: {:.4f}'.format(epoch + 1, n
65      # 保存训练好的模型
66      torch.save(model.state_dict(), 'model_skl.ckpt')
67
68  # Test the model 测试模型
69  def test_model(model, test_loader, device):
70      model.load_state_dict(torch.load('model_skl.ckpt', map_location=device))
71      with torch.no_grad():
72          correct = 0
73          total = 0
74          for images, labels in test_loader:
75              images = images.reshape(-1, 8 * 8).to(device)
76              labels = labels.reshape(1).to(device)
77              outputs = model(images)
78              _, predicted = torch.max(outputs.data, 1)
79              total += labels.size(0)
80              correct += (predicted == labels).sum().item()
81          print('Accuracy is: {}%'.format(100 * correct / total))
82
83  train_model(model, train_loader)
84  test_model(model, test_loader, device)
```